

MedAgent-Flow: Agentic Architecture with MedGemma

Gustavo Barros¹[pg61527], Rui Rodrigues¹[pg61544], Enzo Vieira¹[pg61518], João Macedo¹[pg60274], and Jorge Pereira¹[pg60276]

¹ Universidade do Minho, Campus de Gualtar, 4710-057 Braga, Portugal
geral@uminho.pt
<https://www.uminho.pt>

Abstract. Este relatório descreve o desenvolvimento de um protótipo de tutoria médica agentic baseado em MedGemma, concebido para apoiar treino clínico em cenários de anamnese e interpretação radiológica. A solução organiza-se em grafos de decisão com orquestração central, agentes especializados e avaliação estruturada do desempenho do estudante. O sistema procura equilibrar raciocínio clínico, naturalidade conversacional e mecânicas de gamificação. A avaliação considera exatidão diagnóstica, eficiência na interação e progressão do aluno, ao mesmo tempo que o frontend apresenta uma experiência guiada, com relatório final e fontes clicáveis quando existem documentos de suporte. Além da implementação técnica, o trabalho discute a viabilidade de gerar casos sintéticos com base em modelos fundacionais, a separação entre dados clínicos e conteúdo de treino, e implicações de acessibilidade e inclusividade numa plataforma de educação médica.

Keywords: MedGemma · agentic AI · medical education · LangGraph · gamification · RAG

1 Introdução

1.1 Contextualização e Motivação

A prática clínica é inseparável do desenvolvimento de raciocínio diagnóstico. Contudo, expor estudantes a cenários reais implica riscos para o doente, pressão temporal incompatível com a aprendizagem e dependência de casos disponíveis no momento. Estas limitações estruturais da educação médica tradicional foram amplamente documentadas na literatura e motivaram décadas de investigação em simulação clínica.

Os sistemas de tutoria inteligente (ITS — **Intelligent Tutoring Systems**) procuram suprir esta lacuna através de ambientes computacionais capazes de adaptar o conteúdo ao nível do estudante e fornecer feedback imediato. No domínio médico, estes sistemas evoluíram de bases de regras estáticas para abordagens híbridas que combinam modelos probabilísticos com representações de conhecimento clínico.

A chegada dos grandes modelos de linguagem (LLMs — **Large Language Models**) abriu uma nova dimensão: a possibilidade de gerar diálogos clínicos plausíveis, raciocinar sobre sintomas e diagnósticos com linguagem natural e adaptar o discurso ao perfil do interlocutor. O MedAgent-Flow explora esta possibilidade através de uma arquitetura multi-agente que coordena LLMs especializados em papéis distintos dentro de um fluxo de consulta completo.

1.2 Problema

A maioria das plataformas de simulação clínica disponíveis comercialmente ou academicamente apresenta uma ou mais das seguintes limitações:

- **Rigidez conversacional:** fluxos pré-definidos que não se adaptam às escolhas do estudante.
- **Ausência de avaliação automática:** o feedback depende de supervisores humanos.
- **Dependência de dados reais:** sistemas que requerem registros clínicos hospitalares para treino ou operação.
- **Falta de explicabilidade:** respostas do sistema não são fundamentadas em literatura rastreável.

O MedAgent-Flow propõe-se resolver estas limitações através de uma arquitetura agentic com grafos de controlo explícito, avaliação automática integrada e suporte a RAG com documentação.

1.3 Contribuições Principais

Este projeto contribui com:

1. **Arquitetura multi-agente para tutoria clínica** — orquestração de agentes com papéis distintos (tutor, paciente, narrador, avaliador) usando LangGraph.
2. **Separação de responsabilidades entre modelos** — MedGemma para raciocínio clínico, Gemma para interação conversacional.
3. **Avaliação automática progressiva** — métricas de cobertura de sintomas, qualidade diagnóstica e eficiência de sessão.
4. **RAG com fundamentação documental** — respostas do tutor fundamentadas em literatura e apresentadas com fontes clicáveis.
5. **Gamificação pedagógica** — pontuação que reflete competência clínica e alimenta feedback personalizado.

1.4 Estrutura do Documento

O documento está organizado da seguinte forma: a Secção 2 revê o estado da arte em educação médica assistida por IA; a Secção 3 descreve a arquitetura global do sistema; a Secção 4 detalha a estratégia de integração dos modelos; a Secção 5 documenta a implementação dos módulos; a Secção 6 apresenta a metodologia de avaliação; a Secção 7 aborda gamificação; a Secção 8 discute RAG e fontes documentais; a Secção 9 trata acessibilidade e inclusividade; a Secção 10 aborda

ética e privacidade; a Secção 11 apresenta resultados preliminares; e a Secção 12 discute trabalho futuro e conclusão.

2 Estado da Arte

2.1 Simulação Clínica e Sistemas de Tutoria Inteligente

A simulação clínica tem raízes nos simuladores de manequim físico dos anos 1960, evoluindo para sistemas baseados em computador nas décadas seguintes [1]. Os ITS modernos distinguem-se por incorporar modelos do estudante, modelos pedagógicos e modelos de domínio que interagem dinamicamente para adaptar a experiência de aprendizagem [2].

No domínio médico, plataformas como o Aquifer e o DxR Clinician popularizaram a simulação de casos clínicos baseados em texto, enquanto sistemas como o Harvey Cardiac Patient Simulator introduziram feedback audiovisual. O MedAgent-Flow situa-se nesta linha, mas substitui as bases de regras por agentes baseados em LLMs com capacidade de resposta generativa.

2.2 Grandes Modelos de Linguagem em Medicina

A aplicação de LLMs ao domínio médico foi marcada por resultados notáveis. O GPT-4 demonstrou desempenho próximo do limiar de aprovação no USMLE (United States Medical Licensing Examination) sem fine-tuning específico [3]. O Med-PaLM 2 da Google alcançou resultados comparáveis a especialistas humanos em benchmarks clínicos [4].

O MedGemma, lançado pela Google em 2024, representa o estado da arte para modelos de código aberto orientados ao domínio médico. Com 27 mil milhões de parâmetros e treino específico em literatura biomédica e imagens clínicas, oferece capacidades de raciocínio clínico superiores a modelos generalistas de dimensão equivalente. O MedAgent-Flow utiliza a variante de instrução (`medgemma-27b-it`) quantizada em GGUF (Q8_0) para inferência local eficiente.

2.3 Arquiteturas Multi-Agente

A decomposição de sistemas de IA em agentes com papéis especializados emergiu como paradigma dominante para tarefas complexas [5]. Frameworks como o AutoGen [6] e o LangGraph [7] fornecem primitivas para orquestrar agentes com memória partilhada, passagem de mensagens e controlo de fluxo baseado em grafos.

No contexto educacional, a separação de papéis entre tutor, estudante simulado e avaliador é bem estabelecida na literatura [8]. O MedAgent-Flow estende este modelo ao domínio médico, adicionando um papel de narrador que contextualiza os cenários e um papel de paciente virtual que responde de forma plausível às perguntas do estudante.

2.4 Retrieval-Augmented Generation

O RAG foi introduzido como mecanismo para fundamentar respostas de LLMs em documentos externos, reduzindo alucinações e aumentando a rastreabilidade [9]. Em contextos médicos, o RAG é particularmente relevante porque permite associar respostas clínicas a literatura curada, diretrizes clínicas ou protocolos institucionais sem necessidade de fine-tuning contínuo.

O MedAgent-Flow integra um pipeline RAG completo, ingestão, chunking, embeddings e recuperação, que alimenta os nós clínicos do MedGemma com contexto documental relevante. Os documentos recuperados são apresentados ao estudante como fontes clicáveis, reforçando a explicabilidade do sistema.

3 Arquitetura do Sistema

3.1 Visão Global

O MedAgent-Flow está organizado em três camadas lógicas que refletem a separação de responsabilidades do sistema:

Camadas da Arquitetura

Camada de Orquestração — Seleção dinâmica do módulo clínico e gestão do perfil do estudante. Implementada como grafo LangGraph com nó de router.

Camada de Domínio — Subgrafos independentes para anamnese e radiologia. Cada subgrafo encapsula os seus próprios agentes, estado e critérios de avaliação.

Camada de Interface — Frontend que apresenta o diálogo, os botões de fontes documentais e o painel de relatório final.

Esta arquitetura em camadas evita o antipadrão do chatbot monolítico: cada nó tem responsabilidade delimitada, o estado é explícito e o comportamento é previsível e testável.

3.2 Grafo de Orquestração Principal

O grafo principal segue o seguinte fluxo de execução:

```
[START]
  ↳ load_student_profile      # carrega histórico e preferências
    ↳ module_router          # seleciona anamnese ou radiologia
      ↳ [anamnesis_subgraph]
      ↳ [xray_subgraph]
        ↳ session_finalizer  # consolida estado e metadados
          ↳ [END]
```

O nó `module_router` toma a sua decisão com base em múltiplos sinais: preferências do estudante, módulos já completados na sessão atual, e avaliação do conteúdo da primeira mensagem do utilizador. Este último mecanismo permite iniciar o módulo correto mesmo quando o estudante não especifica explicitamente o domínio pretendido.

A memória de sessão é mantida num objeto de estado partilhado que percorre o grafo. Este estado inclui o perfil do estudante, o histórico de mensagens, os metadados da sessão e o estado interno de cada módulo ativo. A persistência entre nós é garantida pelo mecanismo de anotações de estado do LangGraph.

3.3 Subgrafo de Anamnese

O módulo de anamnese simula uma consulta médica completa, desde a apresentação do doente até à formulação de hipóteses diagnósticas. O subgrafo inclui os seguintes nós:

Agente	Responsabilidade	Modelo
Narrador	Apresenta o cenário clínico e contextualiza a consulta	Gemma
Paciente Virtual	Responde a perguntas do estudante de forma plausível	Gemma
Tutor Clínico	Avalia perguntas, sugere pistas, fornece feedback	MedGemma
Avaliador	Acompanha cobertura de sintomas, qualidade diagnóstica e gera o relatório final	MedGemma


O estado da sessão de anamnese inclui:

- **Persona do doente:** nome, idade, género, contexto social e profissional.
- **Diagnóstico oculto:** a verdade de referência, não revelada ao estudante.
- **Lista de sintomas-alvo:** sintomas que o estudante deve descobrir através das suas perguntas.
- **Evaluation sheet:** registo de sintomas cobertos, tentativas de diagnóstico e respetiva qualidade.
- **Histórico de mensagens:** conversa completa entre estudante e sistema.

Com base nas componentes que estruturam o estado da sessão, o sistema gere a experiência do utilizador através de um ciclo iterativo de perguntas, respostas e avaliações em tempo real. Este dinamismo operacional é detalhado no fluxo seguinte:

Fluxo de Interação na Anamnese

Narrador apresenta cenário



tentativa

A decisão de encerrar a sessão ocorre quando o estudante formula um diagnóstico correto, atinge o limite de tentativas ou solicita explicitamente o relatório final.

3.4 Subgrafo de Radiologia

O módulo de radiologia apresenta imagens médicas (radiografias, TC ou RM) e guia o estudante na identificação de achados e formulação de uma impressão radiológica. O subgrafo inclui os seguintes nós:


Agente	Responsabilidade	Modelo
Interpreter	Analisa a imagem clínica e extrai os achados de referência e a impressão correta	MedGemma
Presenter	Apresenta o caso radiológico ao estudante e formata a interação inicial	Gemma
Tutor Clínico	Acompanha os pedidos de informação, corrige desvios e orienta a interpretação	MedGemma
Avaliador	Avalia os achados identificados, a impressão radiológica e gera o relatório final	MedGemma

O estado da sessão de radiologia inclui:

- **Imagem clínica:** fornecida como base64 ou referência a ficheiro local.

- **Achados de referência:** lista de findings extraídos pelo interpreter a partir da imagem.
 - **Achados do estudante:** histórico de observações submetidas e respetiva validação.
 - **Impressões do estudante:** histórico das conclusões radiológicas formuladas ao longo da sessão.
 - **Evaluation sheet:** registo de achados corretos, incorretos e impressões avaliadas.
 - **Histórico de mensagens:** conversa completa entre estudante e sistema.
- O MedGemma é invocado no interpreter para inferir a leitura clínica da imagem e no avaliador para atribuir pontuação e gerar feedback específico. Esta capacidade multimodal é uma das características distintivas do modelo escolhido.

Fluxo de Interação na Radiologia



4 Modelos e Estratégia de Inferência

4.1 Arquitetura de Modelos

O MedAgent-Flow distingue explicitamente entre dois perfis de modelo, configurados por variáveis de ambiente:

Variável	Modelo	Temperatura	Contexto	Funções
MEDICAL_MODEL	medgemma-27b-it-GGUF:Q8_0	0.1	Clínico	Tutor, avaliador, radiologia, relatório

CHAT_MODEL	gemma-2-9b-it	0.7	Con-versa-cional	Router, paciente, narrador, apresentação
------------	---------------	-----	------------------	--

Esta separação não é meramente técnica. Ela reflete uma decisão pedagógica: o conteúdo clínico deve ser consistente, rigoroso e rastreável (daí a temperatura baixa no MedGemma), enquanto a interação conversacional deve ser natural e adaptada ao contexto emocional da consulta simulada.

4.2 MedGemma: Raciocínio Clínico

O MedGemma-27B-IT é um modelo de instrução treinado pela Google com foco específico no domínio biomédico. As suas capacidades principais relevantes para este projeto são:

Capacidades Multimodais O modelo aceita imagens médicas como input, permitindo a análise de radiografias, TC e RM sem recorrer a modelos separados de visão computacional. Isto simplifica a arquitetura do módulo de radiologia e mantém a coerência do raciocínio entre a análise visual e a geração de feedback textual.

Conhecimento Clínico Especializado O treino em literatura biomédica confere ao modelo familiaridade com terminologia, protocolos diagnósticos e raciocínio diferencial que modelos generalistas não possuem de forma consistente. Isto é crítico num sistema de tutoria onde erros clínicos sistemáticos comprometem a validade pedagógica.

Configuração de Inferência O modelo é servido através de uma API compatível com OpenAI, com `base_url` dedicada configurável por variável de ambiente. A quantização Q8_0 em formato GGUF permite inferência eficiente em hardware com GPU de consumidor (≥ 24 GB VRAM) sem perda significativa de qualidade

4.3 Gemma: Fluxo Conversacional

O modelo Gemma-2-9B-IT serve as componentes conversacionais do sistema onde a naturalidade e a fluidez são prioritárias face ao rigor clínico:

- Router do orquestrador: classifica a intenção do estudante e seleciona o módulo adequado.
- Paciente virtual: gera respostas plausíveis a perguntas do estudante, mantendo coerência com a persona definida.
- Narrador: apresenta cenários clínicos com linguagem envolvente e contextualmente adequada.
- Presenter: formata e apresenta respostas do sistema ao estudante.

A temperatura mais elevada (0.7) neste modelo produz variabilidade natural nas respostas do paciente, evitando que o sistema pareça repetitivo em sessões múltiplas com o mesmo caso.

4.4 Implicações da Separação de Modelos

Esta decisão arquitetural tem consequências positivas para além da qualidade das respostas:

Rastreabilidade: quando o relatório final referencia uma avaliação clínica, é possível associá-la inequivocamente ao MedGemma, enquanto as respostas conversacionais são atribuídas ao Gemma. Isto facilita a auditoria do comportamento do sistema.

Flexibilidade: a configuração por variáveis de ambiente permite substituir qualquer um dos modelos sem alterar a arquitetura.

Custo computacional: reservar o modelo maior (27B) apenas para as tarefas que o justificam reduz a latência média da sessão e os requisitos de hardware.

5 Implementação

5.1 5.1. Tecnologias, Frameworks e Ambiente de Desenvolvimento

O sistema foi implementado com uma separação clara entre backend e frontend. O backend em Python concentra a orquestração dos agentes, a execução dos modelos de linguagem, a avaliação automática e a infraestrutura de RAG; o frontend em TypeScript apresenta a interface do estudante e consome a API do servidor.

Tecnologia	Uso no projeto	Justificação
Python	Backend, orquestração de IA, avaliação e RAG	Permite integração direta com modelos, bibliotecas científicas e código assíncrono de API.
FastAPI	Exposição dos endpoints REST e gestão de dependências	Oferece desempenho assíncrono, tipagem via Pydantic e documentação automática.
LangGraph	Orquestração do fluxo principal e dos sub-grafos clínicos	Modela o comportamento multiagente como grafo com estado persistente e decisões condicionais.

SQLAlchemy + asyncpg	Acesso a PostgreSQL para chats, utilizadores e documentos	Mantém persistência transa- cional e compatibilidade com o ecossistema Python assín- crons.
PostgreSQL + pgvector	Armazenamento rela- cional e base vetorial do RAG	Consolida metadados, chunks e embeddings no mesmo motor de dados.
TypeScript + React + Vite	Frontend do estudante e painéis de sessão	Garante interface reativa, de- senvolvimento rápido e boa integração com o ecossistema moderno de UI.
Tailwind CSS	Estilização da interface	Facilita consistência visual e velocidade de implementação sem bloquear componentes acessíveis.
OpenAI-com- patible APIs	Inferência dos modelos Gemma/MedGemma e embeddings	Permite trocar o backend de modelos sem reescrever a aplicação.

O ambiente é configurado por variáveis de ambiente e por arranque do próprio servidor. O backend carrega as configurações com `load_dotenv()`, inicializa a aplicação FastAPI com CORS para o frontend e cria as tabelas na fase de **lifespan** através de `Base.metadata.create_all`. A execução local é complementada por `docker-compose` e pelos scripts de migração e lint existentes no repositório.

5.2 Módulo do Tutor Clínico Virtual (Motor de Diálogo)

O motor de diálogo é construído sobre o grafo principal do LangGraph e sobre os subgrafos específicos de cada domínio. A sessão é identificada por `thread_id`, o que permite retomar o estado da conversa a partir do mesmo fluxo mesmo depois de múltiplos pedidos HTTP. O backend chama `graph.get_state(config)` para detetar se a sessão é nova e usa `Command(resume=...)` para continuar a execução quando o utilizador envia novas mensagens ou uma hipótese diagnóstica.

A memória de curto prazo está embebida no estado da sessão. O modelo partilha estruturas como `messages`, `turn_count`, `gave_up`, `route_decision`, `diagnosis_attempts` e os estados específicos de cada módulo, por exemplo `impression_attempts` e `evaluation_sheet` na radiologia. Isto evita depender de uma base de dados intermédia para a lógica conversacional: a persistência opera-

cional acontece no grafo e no checkpointer, enquanto a base de dados relacional guarda os metadados necessários para autenticação e histórico.

A engenharia de prompts está distribuída por funções dedicadas em `domains/*/prompts`. Cada nó recebe um **system prompt** específico para o seu papel. Na radiologia, por exemplo, o **interpreter** analisa a imagem e extrai achados de referência, o **presenter** formata a apresentação do caso, e os nós de tutor usam prompts distintos para responder ao aluno quando a pergunta está fora de contexto, quando a impressão está errada ou quando a interação deve continuar de forma normal. Na anamnese, a mesma estratégia é aplicada a narrador, paciente virtual, tutor e avaliador.

O controlo de fluxo é totalmente explícito. O router do módulo classifica a entrada do estudante como relevante, irrelevante ou tentativa de diagnóstico e escolhe entre tutor, avaliação ou relatório final. No caso da radiologia, `evaluate_input` e `evaluate_impression` fazem a passagem entre respostas pedagógicas e encerramento do caso; na anamnese, a lógica é equivalente, mas adaptada à descoberta progressiva de sintomas e hipóteses diagnósticas. O resultado é um tutor que intervém de forma mais proativa sempre que o estudante se afasta do objetivo clínico.

5.3 Sistema de Avaliação Formativa e Feedback Adaptativo

A avaliação é implementada como uma camada separada da conversação. O contrato genérico está em `core/evaluator.py`, onde a pontuação máxima é de 100 pontos e as notas finais são convertidas numa escala de A a F. Cada domínio herda este contrato, mas calcula a pontuação com regras próprias.

Na anamnese, a nota resulta da combinação entre precisão diagnóstica, eficiência no número de tentativas e cobertura de sintomas. Os valores são computados em `domains/anamnesis/scoring.py`: o diagnóstico exato vale 70 pontos, diagnósticos do mesmo grupo ou relacionados recebem pontuação intermédia, as tentativas rendem até 20 pontos e a cobertura dos sintomas-alvo contribui com até 10 pontos. Na radiologia, `domains/xray/evaluator.py` agrega a identificação correta de achados, a qualidade da impressão radiológica, a penalização de achados falsos e a eficiência da resposta.

É importante notar que estas penalizações não são gravadas como linhas de avaliação numa tabela própria. O backend guarda o comportamento do estudante no estado da sessão e na `evaluation_sheet`, e a pontuação final é calculada quando o caso termina. Isto reduz acoplamento, evita inconsistência entre módulos e facilita reprocessar a sessão para produzir o relatório final.

O mecanismo de intervenção é derivado do mesmo estado. Quando o estudante formula uma pergunta irrelevante, o **router** aumenta o contador de irrelevância e pode encaminhar a sessão para um nó de tutor mais diretivo. Quando a resposta contém uma tentativa de diagnóstico ou impressão, o sistema avalia a precisão, atualiza a `evaluation_sheet` e decide se deve continuar, corrigir ou encerrar com relatório. No final, o modelo médico gera o feedback qualitativo a partir do histórico da sessão e do score calculado.

5.4 Integração do Módulo RAG

A infraestrutura de RAG está centrada no PostgreSQL com `pgvector`. Os documentos são enviados pelos endpoints de `documents_router.py`, que exigem autenticação de docente, validam o tipo de ficheiro e impõem um limite de tamanho de 20 MB. Depois da receção, `ingest_document()` extrai o texto, divide-o em chunks e grava tanto o ficheiro original como os chunks vetorizados na base de dados.

O pipeline de ingestão começa com `extract_text()` para PDF, DOCX, TXT ou Markdown e segue com `split_text()`, que usa `RecursiveCharacterTextSplitter` com chunking configurável. As dimensões e o número de chunks são controlados por `RAGConfig`, o que permite ajustar a granularidade sem alterar o código do domínio clínico.

A geração de embeddings é feita através de um cliente OpenAI-compatible apontado por configuração (`RAG_EMBED_BASE_URL` e `RAG_EMBED_MODEL`, por omissão `bge-m3`). O backend chama `embed_documents()` durante a ingestão e `embed_query()` quando precisa de procurar contexto. A recuperação usa uma consulta SQL com similaridade vetorial (`c.embedding <=> :qvec`) e devolve os chunks mais próximos acima de um limiar configurável.

No momento da execução clínica, `augment_with_rag()` injeta o contexto recuperado diretamente no **system prompt** do nó que vai responder e `attach_sources()` guarda os documentos de apoio no resultado da mensagem. Assim, o RAG não é apenas um mecanismo de pesquisa documental: ele alimenta o raciocínio do tutor e preserva as fontes associadas à resposta apresentada ao estudante.

5.5 Comunicação e APIs (Integração de Módulos)

A comunicação entre frontend e backend é feita por APIs REST síncronas. No frontend, `src/lib/api.ts` centraliza chamadas como `sendMessage`, `createChat`, `getChat`, `submitDiagnosis`, `giveUp`, `uploadDocument` e `deleteDocument`. Todas usam `fetch()` com `credentials: "include"`, o que reflete a integração com autenticação baseada em sessão/cookies.

Do lado do backend, `main.py` expõe `/chat`, `/chat/{thread_id}`, `/chat/{thread_id}/diagnose`, `/chat/{thread_id}/give-up`, `/chats`, `/documents` e `/models/health`. A resposta é serializada por `serialize_state()`, que converte o estado interno do LangGraph em JSON consumível pela interface e separa `messages` de `session`.

O fluxo de dados é simples e previsível: o frontend envia a mensagem do estudante, o backend retoma o estado associado ao `thread_id`, executa o subgrafo apropriado e devolve a sessão atualizada. O código atual não usa WebSockets nem Server-Sent Events para streaming token a token; a experiência é de pedido-resposta síncrono, com geração completa do texto no servidor antes de a resposta regressar ao cliente. Ainda assim, o uso de estados persistentes e subgrafos faz com que a interação pareça contínua para o utilizador.

6 Avaliação Automática

6.1 Princípios de Design

A avaliação no MedAgent-Flow assenta em três princípios fundamentais:

- **Avaliação baseada em comportamento:** O sistema regista as ações do estudante ao longo da sessão (perguntas relevantes, sintomas descobertos e tentativas de diagnóstico) e avalia o percurso clínico completo, e não apenas o resultado final.
- **Progressividade:** A pontuação é acumulada de forma incremental ao longo da sessão. A geração de feedback é contínua e culmina num relatório final estruturado.
- **Interpretabilidade:** O relatório final inclui evidências pedagógicas claras (sintomas validados, tentativas efetuadas e achados identificados) que tornam o feedback diretamente acionável para o utilizador.

6.2 Estrutura do Sistema de Avaliação

O sistema processa a avaliação automática através de módulos especializados por domínio clínico, combinando regras de pontuação exatas com a capacidade analítica do modelo de linguagem médico:

- **Módulo de Anamnese:** Responsável por avaliar a relevância das perguntas feitas ao paciente, a exatidão das hipóteses de diagnóstico e o cálculo da pontuação da consulta.
- **Módulo de Radiologia:** Focado na validação dos achados visuais identificados pelo estudante, na precisão da impressão radiológica e na aplicação de penalizações por erros conceituais.
- **Contrato Genérico de Avaliação:** Define a pontuação máxima global (100 pontos) e estabelece os limiares de conversão das notas finais em escalas de desempenho (de A a F).

Após o cálculo matemático dos pontos, o modelo de inteligência artificial médica é acionado. Com base no histórico da sessão e enriquecido por fontes de referência científica, o modelo gera os textos de feedback personalizado e as justificações pedagógicas.

6.3 Regras de Pontuação

As regras estão estruturadas de forma independente para cada cenário clínico, garantindo que os critérios refletem a realidade da prática médica:

Cenário de Anamnese

A pontuação reflete a capacidade de recolha de dados e o raciocínio clínico diferencial do estudante:

- **Precisão Diagnóstica (até 70 pontos):** Atribui pontuação máxima para o diagnóstico exato, valores intermédios para diagnósticos do mesmo grupo clínico ou patologias relacionadas, e zero pontos para diagnósticos incorretos.
- **Eficiência de Tentativas (até 20 pontos):** Recompensa a assertividade. A pontuação máxima é atribuída à primeira tentativa, decrescendo progressivamente até zero se forem necessárias mais de três tentativas.
- **Cobertura de Sintomas (até 10 pontos):** Pontuação proporcional à percentagem de sintomas-alvo que o estudante conseguiu extrair do paciente virtual através das suas perguntas.

Cenário de Radiologia

A pontuação foca-se na acuidade visual e na interpretação correta dos exames de imagem:

- **Identificação de Achados (até 80 pontos):** Avalia a capacidade de observação do estudante, sendo calculada de forma proporcional ao volume de achados clínicos corretamente identificados na imagem.
- **Qualidade da Impressão Radiológica (até 10 pontos):** Mede a coerência clínica entre o que foi observado e a conclusão final formulada, distinguindo descrições exatas de diagnósticos parcialmente corretos.
- **Penalização por Falsos Positivos (0 a -20 pontos):** Deduz pontos caso o estudante identifique achados inexistentes ou clinicamente irrelevantes, incentivando o rigor na análise.
- **Eficiência de Tentativas (até 10 pontos):** Recompensa a resolução do caso com o menor número de submissões possível.

6.4 Estrutura do Relatório Final

O relatório consolidado é estruturado de forma a garantir uma transição fluida entre a análise do servidor e a visualização do utilizador, contendo os seguintes elementos principais:

Componente	Conteúdo Descritivo
Feedback Qualitativo	Textos gerados pela IA detalhando os pontos fortes, áreas de melhoria e uma síntese geral do desempenho.
Métricas Quantitativas	Pontuação final agregada (numa escala de 0 a 100) e a respetiva nota qualitativa (A, B, C, D ou F).
Evidências Clínicas	Listagem detalhada dos sintomas descobertos, achados validados e o histórico de tentativas de diagnóstico.
Fontes Documentais	Referências e documentos de suporte científico integrados que justificam as correções aplicadas.

7 Gamificação

7.1 Papel da Gamificação no Contexto Pedagógico

A gamificação no MedAgent-Flow é aplicada como um mecanismo estritamente pedagógico: a pontuação não serve apenas como um elemento competitivo, mas sim como uma representação clara de competências expressas pelo estudante que orienta as intervenções do tutor. A gamificação atua na tradução visual do progresso, reduzindo a ambiguidade e ajudando o estudante a calibrar a sua autoavaliação face ao desempenho real.

7.2 Mecânicas e Dinâmicas de Jogo

O sistema traduz o progresso pedagógico através das seguintes mecânicas visuais e funcionais:

- **Pontuação Progressiva e Graus:** O utilizador acompanha a evolução da sua nota em tempo real com base nas suas decisões, recebendo uma classificação por letras no encerramento do caso, exposta de forma clara nos painéis da interface.
- **Adaptatividade do Tutor Baseada no Desempenho:** O fluxo da sessão adapta-se ao rendimento do estudante. Perante escolhas clínicas incorretas, perguntas irrelevantes ou desvios do raciocínio esperado, o tutor clínico inter-vém de forma mais proativa, fornecendo pistas e orientações para guiar o estudante de volta ao caminho correto.
- **Foco no Progresso Individual:** O design atual prioriza a superação do cenário clínico e o feedback formativo personalizado, assegurando que cada utilizador consolide as suas competências ao seu próprio ritmo, sem a pressão competitiva de tabelas de liderança ou classificações públicas.

8 RAG e Fontes Documentais

Os agentes pedagógicos da plataforma (tutores e geradores de relatório final) beneficiam de conhecimento clínico atualizado e alinhado com a bibliografia da disciplina. Para o garantir, o sistema integra um mecanismo de **Retrieval-Augmented Generation** (RAG): em vez de depender exclusivamente do conhecimento paramétrico do modelo médico, o raciocínio é fundamentado em material de referência fornecido pelo docente. Este capítulo descreve como esses documentos são ingeridos e indexados, como são recuperados de forma seletiva durante uma sessão, a que agentes são aplicados e como as fontes utilizadas são apresentadas ao estudante de forma transparente. O objetivo é duplo: reduzir alucinações e alinhar o feedback com o currículo de cada turma.

8.1 Ingestão e Indexação de Documentos

O professor carrega documentos de referência (apontamentos, guias clínicos, artigos) através de uma área dedicada da aplicação, num *endpoint* protegido por *user role*, i. e. apenas docentes podem carregar ou eliminar material. São aceites os formatos PDF, DOCX, TXT e Markdown, até 20 MB por ficheiro.

Após o carregamento, cada documento percorre um pipeline de indexação: o texto é extraído, dividido em fragmentos (*chunks*) de cerca de 800 caracteres com sobreposição de 100 caracteres. Cada fragmento é convertido num vetor numérico (*embedding*) através do modelo BGE-M3 (1024 dimensões), servido por uma API compatível com OpenAI. Os vetores são guardados numa base de dados vetorial *pgvector*, que permite pesquisas de similaridade sobre todo o corpus.

8.2 Recuperação e Fundamentação Seletiva

Durante uma sessão, antes de um agente pedagógico (tutores e geradores de relatório final) responderem, é construída uma *consulta* a partir do último turno do estudante combinado com a verdade do caso (o diagnóstico ou os achados ocultos). Essa consulta é embebida em tempo real e comparada, por similaridade de cosseno, com os fragmentos indexados. São considerados os três fragmentos mais relevantes (*top-K = 3*).

Para evitar fundamentar respostas em correspondências fracas, aplica-se um filtro pelo melhor resultado (*gate top-1*): se o fragmento de maior pontuação não atingir o limiar de similaridade (cerca de 0.55), todos os fragmentos são descartados e a resposta é gerada sem aumento. Quando há excertos relevantes, estes são injetados no *system prompt* sob uma secção de excertos de referência, com instrução explícita para o modelo não inserir citações no corpo do texto, a rastreabilidade é assegurada à parte (ver Section 8.4).




Fig. 1. RAG pipeline.

8.3 Aplicação Seletiva aos Agentes

O RAG não é aplicado a todos os componentes do sistema, mas apenas aos seis nós de raciocínio clínico: os tutores de anamnese e de radiologia (orientação quando o

estudante se desvia ou erra) e os geradores de relatório final de ambos os módulos. Estes são os momentos em que o sistema produz *feedback* pedagógico e em que a fundamentação na bibliografia é mais valiosa.

Em contrapartida, o agente paciente e o analisador de visão de raio-X nunca recebem material de RAG. Esta separação é deliberada: o paciente deve responder com naturalidade e realismo, sem o registo técnico de um manual; e a interpretação da imagem é uma tarefa de visão, à qual excertos textuais não acrescentam valor e poderiam introduzir enviesamento.

8.4 Atribuição de Fontes e Transparência

Quando uma resposta é fundamentada em documentos, estes são deduplicados por documento (vários fragmentos do mesmo ficheiro contam como uma única fonte) e anexados à resposta. A interface apresenta-os como “botões de fonte”, tanto nas mensagens do tutor como nos painéis de relatório final, permitindo ao estudante abrir o documento original consultado. Esta rastreabilidade tem valor pedagógico: o estudante percebe em que material o *feedback* se baseia e é incentivado a recorrer à fonte primária.

Qualquer utilizador autenticado pode consultar os documentos de referência, mas apenas docentes os podem gerir. Importa ainda distinguir estes documentos de referência (indexados para recuperação) dos casos clínicos de anamnese e radiologia, que constituem material de simulação e não são indexados para RAG.

9 Acessibilidade e Inclusividade

9.1 Princípios de Design Acessível

A acessibilidade é tratada como requisito de produto, não como consideração posterior. Numa ferramenta de treino médico usada por estudantes com perfis e contextos diversos, falhas de acessibilidade não são apenas inconveniências: podem excluir utilizadores com necessidades específicas de um recurso pedagógico crítico.

9.2 Clareza Linguística

A terminologia do sistema é calibrada para estudantes de medicina em formação, não para especialistas. O tutor clínico usa linguagem técnica precisa mas acompanhada de contexto suficiente para que a terminologia seja compreensível pelo estudante-alvo.

O paciente virtual usa linguagem “normal” e evita terminologia médica, replicando o que um estudante encontraria numa consulta real. Esta decisão é pedagogicamente relevante: parte das competências clínicas consiste em traduzir a descrição leiga do doente em conceitos semiológicos.

9.3 Inclusividade dos Casos Clínicos

Os casos clínicos gerados pelo sistema devem evitar pressupostos culturais desnecessários e ser representativos de uma população diversa em termos de género, idade, contexto social e profissional. As personas dos doentes virtuais são geradas com distribuição controlada para garantir exposição do estudante a uma variedade de perfis.

10 Ética e Privacidade

10.1 Limitações Conhecidas e Transparência

O sistema deve ser explícito com os seus utilizadores sobre as suas limitações:

Declaração de Limitações ao Utilizador

O MedAgent-Flow é uma ferramenta de aprendizagem. As respostas geradas pelos seus agentes, incluindo as do tutor clínico e do avaliador, são produzidas por modelos de linguagem que podem conter erros. O sistema não substitui supervisão clínica humana. Os diagnósticos e feedback gerados devem ser tratados como material de aprendizagem sujeito a revisão, não como orientação clínica definitiva.

10.2 Risco de Sobreconfiança

Um risco específico de sistemas de tutoria baseados em LLMs é a sobreconfiança do estudante nas respostas do sistema. Se o modelo gerar feedback errado com confiança elevada, o estudante pode internalizar informação clínica incorreta. Para mitigar este risco:

- O tutor clínico é instruído a expressar incerteza quando apropriado.
- O relatório final inclui uma secção de feedback que avalia o desempenho do utilizador e sugere a revisão dos tópicos específicos do tema avaliado em que foram identificadas dificuldades ou respostas incorretas.
- Os documentos de fonte RAG permitem ao estudante verificar independentemente a base das afirmações do tutor.

10.3 Uso Responsável da IA em Educação Médica

O sistema foi desenhado para ser um recurso complementar, não substituto, da supervisão clínica humana. O seu valor pedagógico está na disponibilidade, na repetibilidade e no feedback imediato, dimensões onde a supervisão humana é inevitavelmente limitada. Nas dimensões de julgamento clínico profundo, nuance ética e validação de competências para exercício clínico real, a supervisão humana permanece insubstituível.

11 Resultados Preliminares e Avaliação do Sistema

Apresentam-se, nesta secção, os resultados qualitativos e as observações iniciais obtidas através de demonstrações controladas, sessões de testes internos e auditorias clínicas exploratórias realizadas ao sistema.

11.1 Avaliação Qualitativa e Observações Principais

As validações preliminares focaram-se na robustez do fluxo de orquestração, na coerência clínica das respostas geradas e na naturalidade conversacional da interface. Durante os ensaios, destacaram-se os seguintes comportamentos:

- **Robustez do Fluxo de Orquestração:** O grafo de orquestração demonstram capacidade para manter um estado consistente, mesmo ao retomar sessões interrompidas. Foi possível encadear eficazmente os nós de anamnese e radiologia sem perda de contexto operacional.
- **Coerência Clínica:** As respostas geradas pelo modelo MedGemma alinharam-se, de forma geral, com os enunciados dos casos clínicos submetidos. Nos cenários em que o mecanismo de RAG (*Retrieval-Augmented Generation*) foi acionado, as justificações apresentadas incluíram referências bibliográficas estruturadas e relevantes.
- **Naturalidade da Interação:** O modelo Gemma exibiu variabilidade e fluidez na simulação dos papéis de paciente e narrador, mitigando padrões repetitivos em sessões consecutivas.
- **Performance Técnica:** As latências medianas de resposta situaram-se dentro de limites aceitáveis para uma interação em tempo real.

Para ilustrar estas observações, a Tab. 1 sintetiza o comportamento do sistema face a cenários tipificados.

Table 1. Sinopse de casos exemplares e comportamento da orquestração.

Caso Clínico	Intervenção do Estudante e Roteamento	Avaliação do Tutor / Logs
Caso Exemplo A (Anamnese)	Exploração de sintomas primários e historial clínico.	Roteamento correto do fluxo; respostas do paciente fluídas.
Caso Exemplo B (Radiologia)	Interpretação incorreta de achados imagiológicos.	Intervenção imediata do tutor clínico sugerindo pistas de correção.

11.2 Metodologia de Auditoria e Limitações

O estado atual da avaliação assenta em três pilares metodológicos executados manualmente:

1. **Auditoria RAG:** Verificação amostral das fontes anexadas às respostas para confirmar a ausência de alucinações e a correlação com as afirmações do tutor.
2. **Testes de Estabilidade:** Execução de múltiplas sessões sequenciais para garantir a integridade da folha de avaliação (`evaluation_sheet`) e a ausência de vazamento de estado (*state leakage*).

Como principais **limitações reconhecidas**, aponta-se a ausência corrente de métricas quantitativas padronizadas (como *accuracy* diagnóstica ou ganho efetivo de aprendizagem), a dimensão reduzida da amostra de revisores e a falta de um protocolo empírico com estudantes de diferentes níveis académicos. Em suma, o protótipo valida a viabilidade técnica do sistema, carecendo contudo de uma validação empírica sistemática.

11.3 Métricas Recomendadas para Estudos Futuros

Com vista a uma validação robusta em trabalhos futuros, propõe-se um ecossistema bimodal de métricas, divididas entre a vertente clínico-pedagógica e a componente estritamente técnica:

Dimensão Clínica e Pedagógica:

- **Accuracy Diagnóstica e Curva Roc:** Proporção de diagnósticos corretos, sensibilidade e especificidade na identificação de achados radiológicos.
- **Ganho de Aprendizagem (G):** Avaliação do diferencial entre o pré-teste e o pós-teste através do cálculo do ganho normalizado.
- **Métricas de Eficiência:** Taxa de completude do caso e número médio de turnos/tentativas até à obtenção do diagnóstico correto.
- **Concordância (Cohen's κ):** Grau de concordância inter-juízes entre o sistema automático e um painel de especialistas humanos.
- **Experiência do Utilizador e Carga Cognitiva:** Aplicação das escalas SUS (*System Usability Scale*) e NASA-TLX.

Dimensão Técnica:

- Latência por pedido (ms) e débito do sistema (*throughput* em req/h).
- Monitorização de recursos *hardware* (VRAM, memória RAM e consumo de tokens por sessão).
- Taxa de alucinação (*hallucination rate*) avaliada por métricas automáticas de fidelidade ao contexto do RAG.

11.4 Protocolo de Piloto Rápido Sugerido

Para a recolha célere das métricas supracitadas, desenhou-se um protocolo experimental mínimo estruturado em cinco etapas consecutivas, a aplicar a uma amostra de 10 a 20 estudantes de medicina:

1. **Pré-teste:** Aplicação de uma avaliação de diagnóstico inicial contendo aproximadamente 10 questões objetivas sobre a matéria médica em apreço.

2. **Interação com o Sistema:** Cada participante completará 3 sessões de treino distintas (um cenário de anamnese, um de radiologia e um caso clínico livre). Os parâmetros de tempo total, turnos e intervenções do tutor serão registrados de forma automatizada.
3. **Pós-teste:** Reaplicação do teste inicial para quantificação estatística do ganho pedagógico.
4. **Inquérito de Satisfação:** Submissão dos questionários SUS e escalas Likert focadas em utilidade e confiança.
5. **Auditoria Cruzada:** Revisão manual por dois peritos de 30% das sessões gravadas para computação do coeficiente κ de Cohen.

12 Trabalho Futuro e Conclusão

12.1 Trabalho Futuro

A natureza modular da arquitetura proposta e implementada neste projeto foi desenhada deliberadamente para permitir a escalabilidade e a evolução contínua do sistema. Identificam-se como prioridades para trabalhos futuros o desenvolvimento e a consolidação do sistema em três frentes principais: expansão de conteúdos médicos, refinamento tecnológico da inteligência artificial e validação pedagógica.

Módulos Clínicos Adicionais

Embora a presente versão se foque primordialmente nos cenários de Anamnese e de Radiologia, a prática médica e o ensino clínico exigem uma abordagem holística e multidisciplinar. Como tal, identificam-se como prioridades para trabalhos futuros o desenvolvimento e a integração de novos módulos fundamentais:

1 Módulo de Urgência e Triagem (Tomada de Decisão sob Pressão Temporal): Para além da precisão diagnóstica, a gestão do tempo é uma competência crítica em ambiente hospitalar. Este módulo introduzirá cenários de alta fidelidade baseados em fluxos de triagem (como o Sistema de Triagem de Manchester). Do ponto de vista técnico, o motor de jogo e o tutor virtual deverão impor restrições temporais estritas e simular a deterioração do estado clínico do paciente virtual em tempo real caso as intervenções prioritárias não sejam executadas atempadamente.

2 Módulo de Análise de Imagem Dermatológica (Diagnóstico Visual de Lesões Cutâneas): O reconhecimento de padrões dermatológicos - assimetria, irregularidade de bordos, variação de cor, diâmetro e evolução (a regra ABCDE) - é uma competência decisiva na deteção precoce de patologias como o melanoma. Este módulo estenderá o pipeline de visão já existente no módulo de Radiologia a imagens dermatoscópicas e clínicas, permitindo ao estudante descrever os achados morfológicos e formular hipóteses diagnósticas, enquanto o tutor

virtual orienta o raciocínio e confronta a impressão do aluno com o diagnóstico de referência.

3 Módulo de Análise Histopatológica (Interpretação de Lâminas):

A correlação entre a apresentação clínica e o substrato tecidual é fundamental para encerrar o percurso diagnóstico. Este módulo introduzirá a interpretação de imagens histopatológicas (lâminas digitalizadas, *whole-slide imaging*), desafiando o estudante a identificar características celulares e arquiteturais e a integrá-las no raciocínio clínico-patológico. Do ponto de vista técnico, exigirá o tratamento de imagens de altíssima resolução e a navegação fluida entre diferentes níveis de ampliação.

Otimização Avançada de RAG

Embora a arquitetura RAG atual garanta o suporte documental das diretrizes médicas, o pipeline de recuperação pode ser significativamente aperfeiçoado através de técnicas de **Advanced RAG**:

- **Mecanismos de Auto-Avaliação (Self-RAG):** Permitir que o sistema avalie autonomamente a qualidade e a relevância do contexto médico recuperado antes de o entregar ao Tutor, gerando uma camada extra de segurança pedagógica.
- **Grafos de Conhecimento Clínico (Knowledge Graphs):** Complementar a pesquisa vetorial pura por uma estrutura baseada em grafos, permitindo que a IA compreenda de forma robusta as relações complexas entre sintomas, patologias e guidelines estruturadas.

Estudos de Validação Clínica e Experiência do Utilizador

Para além do desenvolvimento de software, os passos seguintes incluem a validação empírica do sistema no terreno:

- **Estudos Piloto Controlados:** Submeter a plataforma a testes com grupos de controlo em faculdades de medicina, avaliando o impacto real do tutor virtual no desenvolvimento do raciocínio clínico face aos métodos tradicionais.
- **Avaliação por Painel de Peritos:** Realizar auditorias cegas onde médicos e pedagogos comparam as avaliações e notas atribuídas pela avaliação e o *feedback* dado com aquelas que um professor humano atribuiria aos mesmos diálogos.
- **Interface Multimodal:** Expandir a acessibilidade da interface através da integração de tecnologias de voz (**Voice-to-Text** e **Text-to-Speech**), aproximando a interação com o paciente virtual de uma consulta médica real.

12.2 Conclusão

Para o efeito, desenhamos e implementámos uma plataforma de simulação assente numa arquitetura hierárquica de agentes (LangGraph em dois níveis), na qual um orquestrador encaminha o estudante para o módulo adequado e cada módulo coordena agentes especializados, por exemplo: paciente virtual, tutor e

avaliador. Este desenho modular revelou-se a principal força do sistema: cada papel pedagógico está isolado, o que preserva o realismo do paciente, salvaguarda a integridade da avaliação e permite acrescentar novos módulos sem reescrever o núcleo.

Em torno deste núcleo construímos as restantes camadas descritas ao longo do relatório: um mecanismo de avaliação automática do desempenho, elementos de gamificação que sustentam a motivação, e um sistema de RAG que fundamenta o *feedback* dos tutores em material curricular fornecido pelo docente, reduzindo alucinações e alinhando o sistema com a bibliografia de cada turma. Estas opções foram acompanhadas por uma preocupação transversal com a acessibilidade e a inclusividade da interface e com as questões de ética e privacidade inerentes ao tratamento de dados clínicos.

Os resultados preliminares são encorajadores e demonstram a viabilidade da abordagem, ainda que reconheçamos as limitações de uma validação conduzida em contexto não clínico e à escala de um protótipo. Como discutido na secção de Trabalho Futuro, a consolidação do sistema passará pela expansão dos conteúdos médicos, pelo refinamento das técnicas de recuperação e, sobretudo, pela validação empírica junto de estudantes e peritos. Em síntese, o projeto constitui uma prova de conceito sólida de como modelos de linguagem, devidamente orquestrados e fundamentados, podem complementar, mas **não substituir**, os métodos tradicionais de formação clínica.

Bibliography

1. Issenberg, S.B., McGaghie, W.C., Petrusa, E.R., Gordon, D.L., Scalese, R.J.: Features and uses of high-fidelity medical simulations that lead to effective learning: a BEME systematic review. *Medical Teacher*. 27, 10–28 (2005).
2. VanLehn, K.: The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*. 46, 197–221 (2011).
3. Nori, H., King, N., McKinney, S.M., Carignan, D., Horvitz, E.: Capabilities of GPT-4 on medical challenge problems. *arXiv preprint arXiv:2303.13375*. (2023).
4. Singhal, K., Azizi, S., Tu, T., Mahdavi, S.S., Wei, J., Chung, H.W., Scales, N., Tanwani, A., Cole-Lewis, H., Pfohl, S., Payne, P., Seneviratne, M., Gamble, P., Kelly, C., Babiker, A., Schärli, N., Chowdhery, A., Mansfield, P., Demner-Fushman, D., Arcas, B. Agüera y, Webster, D., Corrado, G.S., Matias, Y., Chou, K., Gottweis, J., Tomasev, N., Liu, Y., Rajkomar, A., Barral, J., Sementurs, C., Karthikesalingam, A., Natarajan, V.: Large language models encode clinical knowledge. *Nature*. 620, 172–180 (2023).
5. Park, J.S., O'Brien, J.C., Cai, C.J., Morris, M.R., Liang, P., Bernstein, M.S.: Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST '23)*. (2023). <https://doi.org/10.1145/3586183.3606763>.
6. Wu, Q., Bansal, G., Zhang, J., Wu, Y., Zhang, S., Zhu, E., Li, B., Jiang, L., Zhang, X., Wang, C.: AutoGen: Enabling next-gen LLM applications via multi-agent conversation framework. *arXiv preprint arXiv:2308.08155*. (2023).
7. LangChain, I.: LangGraph: Build stateful, multi-actor applications with LLMs, <https://langchain-ai.github.io/langgraph/>, last accessed 2024/12/01.

8. Graesser, A.C., Lu, S., Jackson, G.T., Mitchell, H.H., Ventura, M., Olney, A., Louwerse, M.M.: AutoTutor: A tutor with dialogue in natural language. *Behavior Research Methods, Instruments, and Computers*. 36, 180–192 (2004).
9. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., Kiela, D.: Advances in Neural Information Processing Systems. Presented at the (2020).